ENCG Settat

جامعة الحسن الأول
UNIVERSITÉ HASSAN 1ER

PRÉVISION DE L'INFLATION

ÉTUDE DU RÔLE DU CHÔMAGE ET DU TAUX DIRECTEUR DANS LA PRÉVISION DE L'INFLATION À 12 MOIS

Encadré par: M. LARHLIMI

Groupe: FIN3

Réalisé par: LABRAHMI Doha
LAALJ Marwa

Année scolaire: 2026/2027

Sommaire

Contents

Résumé **2**

Introduction et problématique **3**

Présentation et préparation des données **4**

Analyse exploratoire : comprendre les séries **4**
Relations entre les indicateurs 5

Construction du problème de prévision **6**
Définition de la cible à douze mois 6

Construction du problème de prévision **6**
Définition de la cible à douze mois 6
Création des variables retardées 6
Découpage chronologique et validation 6

Présentation des modèles **6**
Modèle de référence : persistance 6
Régression Ridge 6
Gradient Boosting 7

Résultats et comparaison des modèles **7**
Validation croisée temporelle 7
Évaluation finale sur le jeu de test 7
Analyse des erreurs et apprentissage 8

Interprétation des variables **9**

Prévision finale à douze mois **10**

Limites et pistes d'amélioration **10**

Conclusion **11**

Références et sources **12**

Résumé

Cette étude vérifie si le taux de chômage et le taux directeur américains, associés à l'inflation passée, permettent de mieux prévoir l'inflation annuelle douze mois à l'avance. Nous avons construit une base mensuelle à partir de CPIAUCSL, UNRATE et FEDFUNDS, calculé l'inflation sur douze mois, créé des retards, puis comparé une référence de persistance, Ridge et Gradient Boosting.

La base couvre January 1947 à October 2026 (958 mois). Après préparation, 842 observations sont utilisables : 661 pour l'entraînement, 169 pour le test final, avec un intervalle de sécurité de 12 mois.

Modèle	**RMSE test**	**MAE test**	**R^2 test**
Persistance	2.084	1.470	-0.095
Gradient Boosting	2.557	1.771	-0.649
Ridge	2.836	2.004	-1.029

Réponse principale : dans la période et avec les modèles testés, le chômage et le taux directeur n'améliorent pas la prévision par rapport à la persistance. La règle simple qui reconduit l'inflation actuelle obtient le RMSE le plus faible en validation croisée et sur le test. Ce résultat ne prouve pas que ces indicateurs sont économiquement inutiles ; il montre qu'ils n'apportent pas de gain prédictif mesuré dans cette configuration.

Le rapport présente les données, explique les choix méthodologiques, interprète les graphiques et les résultats, puis répond explicitement à la problématique.

Introduction et problématique

L'inflation constitue l'un des phénomènes macroéconomiques les plus suivis par les pouvoirs publics, les banques centrales, les entreprises et les ménages. Elle correspond à une augmentation générale et durable du niveau des prix des biens et des services. Son évolution influence directement le pouvoir d'achat, le coût de la vie, les décisions de consommation et d'épargne des ménages, ainsi que les choix d'investissement et de financement des entreprises. Une inflation élevée ou instable peut également compliquer la planification économique et créer de l'incertitude pour les différents acteurs.

La prévision de l'inflation représente ainsi un enjeu important pour l'analyse économique et financière. Anticiper son évolution permet notamment de mieux comprendre les conditions dans lesquelles les décisions de politique monétaire sont prises. Aux États-Unis, la Réserve fédérale (Federal Reserve) dispose du taux directeur comme instrument de politique monétaire. En agissant sur les conditions de financement, elle cherche à influencer l'activité économique et les pressions sur les prix. Le taux de chômage constitue également un indicateur macroéconomique pertinent, puisqu'il renseigne sur la situation du marché du travail et peut être associé à l'évolution des tensions économiques.

Toutefois, les relations entre l'inflation, le chômage et le taux directeur ne sont pas nécessairement simples ni constantes dans le temps. Elles peuvent varier selon la conjoncture, les périodes historiques et les événements économiques. C'est pourquoi une analyse fondée uniquement sur une observation ponctuelle ou sur une corrélation contemporaine ne suffit pas à déterminer si ces variables permettent réellement d'anticiper l'inflation. Il est nécessaire de tenir compte de leur évolution passée et de tester leur capacité à prévoir une valeur future sur une période qui n'a pas servi à l'apprentissage.

Dans cette perspective, le présent projet F3 porte sur la prévision de l'inflation américaine à un horizon de douze mois, à partir de données mensuelles issues de la base FRED (Federal Reserve Economic Data). L'étude mobilise trois séries principales : l'indice des prix à la consommation (CPIAUCSL), utilisé pour calculer l'inflation annuelle, le taux de chômage (UNRATE) et le taux effectif des fonds fédéraux (FEDFUNDS). Après une étape de nettoyage et d'alignement des séries, des variables retardées sont construites afin de prendre en compte les informations observées au cours des mois précédents.

La démarche consiste ensuite à comparer trois approches de prévision complémentaires. Un modèle de persistance sert de référence : il suppose que l'inflation actuelle constitue une estimation de l'inflation à douze mois. Cette référence est comparée à une régression Ridge, qui permet d'étudier une relation linéaire régularisée entre les indicateurs, et à un modèle Gradient Boosting, capable de représenter des relations plus complexes. Les performances sont évaluées à l'aide d'une validation croisée chronologique et d'un jeu de test distinct, notamment au moyen du RMSE, du MAE et du coefficient de détermination R^2.

L'objectif n'est donc pas seulement de construire un modèle prédictif, mais aussi de vérifier si l'ajout du chômage et du taux directeur apporte une information réellement utile par rapport à une méthode simple. La comparaison permet de discuter les résultats obtenus, d'identifier les limites des modèles testés et de distinguer l'intérêt économique potentiel d'une variable de sa contribution effective à la précision des prévisions dans cette expérimentation.

La problématique qui guide notre travail est donc la suivante :
Le chômage et le taux directeur, associés à l'inflation passée, permettent-ils d'améliorer une prévision simple de l'inflation américaine à un horizon de douze mois ?

Présentation et préparation des données

Les séries proviennent de Federal Reserve Economic Data (FRED), base de données de la Federal Reserve Bank of St. Louis. Elles sont mensuelles et concernent les États-Unis.

Code	Description	Utilisation
CPIAUCSL	Indice des prix à la consommation pour les consommateurs urbains	Calcul de l?inflation annuelle
UNRATE	Taux de chômage civil	Variable explicative
FEDFUNDS	Taux effectif des fonds fédéraux	Variable explicative
INFLATION_YOY	Variation annuelle du CPI en %	Variable d?intérêt et variable explicative

valeurs manquantes pour CPIAUCSL, 14 pour UNRATE, 90 pour FEDFUNDS et 14 pour INFLATION_YOY. Après la création des retards et de la cible, puis l'élimination des lignes incomplètes, l'échantillon de modélisation contient 842 observations, de juillet 1955 à septembre 2025.

Les lignes incomplètes sont supprimées seulement après la construction de la cible et des variables retardées. Cette précaution est essentielle à la cohérence temporelle du projet.

Analyse exploratoire : comprendre les séries

Les statistiques descriptives montrent que l'inflation annuelle a une moyenne de 3.52 %, une médiane de 2.87 %, un écart-type de 2.86 %, un minimum de -2.99 % et un maximum de 14.59 %. Le taux de chômage a une moyenne de 5.65 % ; le taux directeur a une moyenne de 4.59 %.

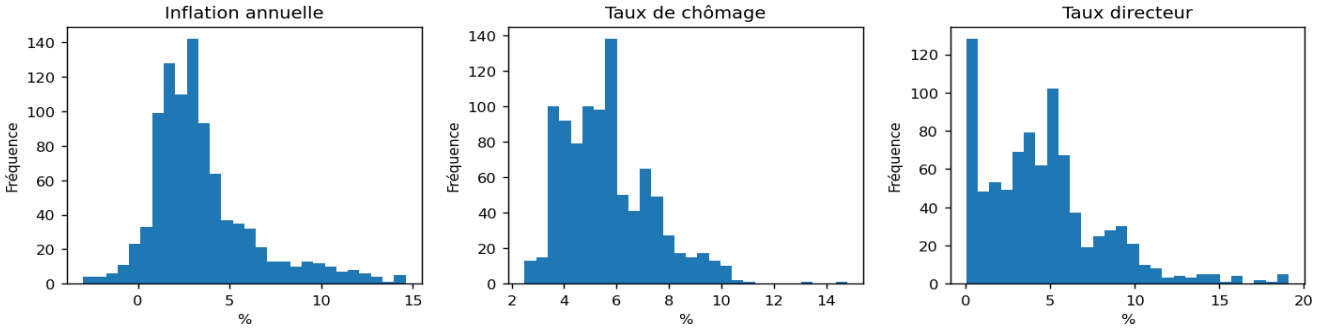


Figure 1 — Distribution de l'inflation annuelle, du chômage et du taux directeur.

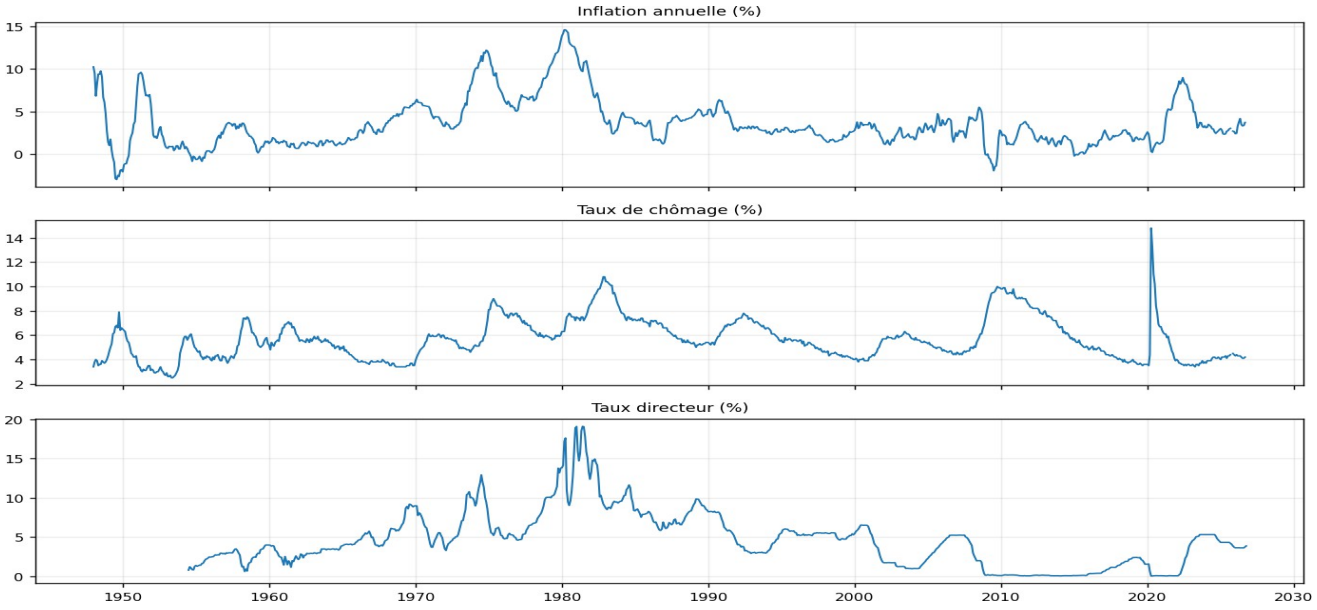


Figure 2 — Évolution historique des trois séries.

La série d'inflation traverse plusieurs régimes : niveaux élevés après la Seconde Guerre mondiale, accélération marquée dans les années 1970 et au début des années 1980, période plus modérée à partir des années 1990, puis nouvelle poussée autour de 2021. Cette succession de phases montre que la relation entre les variables peut changer selon le contexte économique.

Le chômage augmente fortement lors de plusieurs épisodes de crise, notamment en 2009 et en 2020. Le taux directeur présente lui aussi des changements de régime : niveaux très élevés au début des années 1980, baisse après la crise financière de 2008, période proche de zéro au cours des années 2010 et au début de la pandémie, puis remontée à partir de 2022. Ces mouvements rendent plausible l'existence de relations retardées entre politique monétaire, activité économique et inflation.

Relations entre les indicateurs

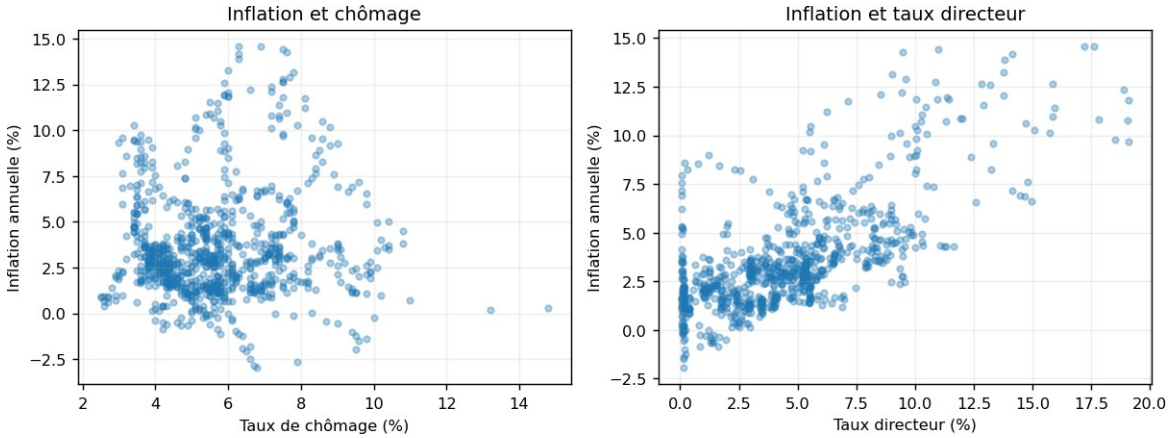


Figure 3 — Nuages de points entre l'inflation et les variables explicatives.

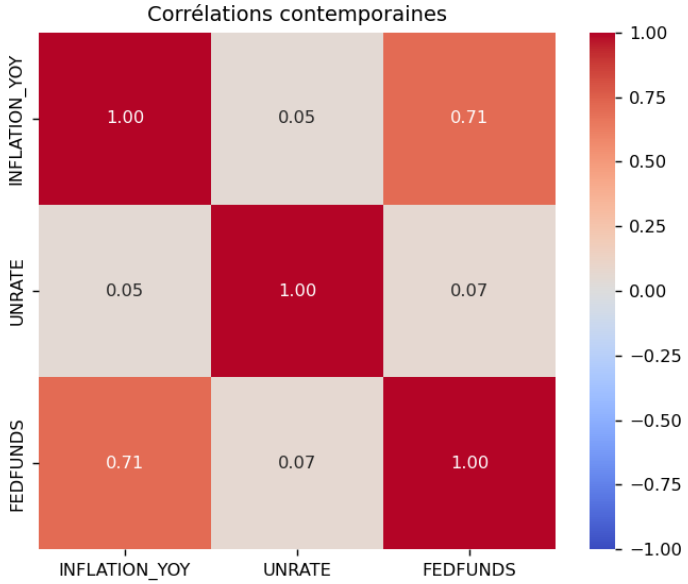


Figure 4 — Corrélations contemporaines.

La corrélation entre inflation et taux directeur est positive et relativement élevée ($r = 0.71$). Une interprétation possible est que la banque centrale relève souvent ses taux lorsque l'inflation augmente. La corrélation contemporaine traduit donc aussi une réaction de politique monétaire ; elle ne prouve pas qu'une hausse du taux directeur provoque une hausse de l'inflation.

Les graphiques et les corrélations décrivent les données, mais ne répondent pas encore à la problématique. La réponse doit reposer sur la performance des prévisions hors échantillon.

Construction du problème de prévision

Définition de la cible à douze mois

Construction du problème de prévision

Définition de la cible à douze mois

Pour chaque date t, la valeur à prévoir est l'inflation annuelle observée douze mois plus tard. La cible est construite par un décalage de -12 périodes de la série INFLATION_YOY : Y(t) = INFLATION_YOY(t+12). Le modèle utilise les variables disponibles à la date t pour estimer cette valeur future.

Création des variables retardées

Les valeurs courantes de l'inflation, du chômage et du taux directeur sont utilisées. Pour chacune de ces séries, le notebook ajoute des retards de 1, 3, 6 et 12 mois. Le jeu final comprend ainsi 15 variables explicatives : trois valeurs courantes et douze valeurs retardées.

Cette construction permet de tester si les valeurs passées du chômage et du taux directeur apportent une information supplémentaire par rapport à l'inflation récente. Les observations incomplètes sont éliminées après cette construction afin de préserver l'alignement des mois.

Découpage chronologique et validation

Ensemble	Observations	Période des dates de départ
Entraînement	661	07/1955 – 07/2010
Intervalle de sécurité	12	Observations écartées avant le test
Test final	169	08/2011 – 09/2025

Le découpage respecte l'ordre temporel : 80 % des observations utilisables sont affectées à la phase de développement, puis 12 observations sont écartées avant le test. L'entraînement comprend 661 observations, de juillet 1955 à juillet 2010. Le test comprend 169 observations, de août 2011 à septembre 2025. Les dates des valeurs cibles du test vont donc d'août 2012 à septembre 2026.

La validation croisée utilise TimeSeriesSplit avec cinq divisions et un intervalle (gap) de 12 mois. Chaque pli entraîne le modèle sur le passé et l'évalue sur une période postérieure. Ce protocole est plus adapté à une série temporelle qu'un découpage aléatoire.

Les pipelines de Ridge et de Gradient Boosting intègrent l'imputation par la médiane ; Ridge ajoute une standardisation. Ces transformations sont ainsi ajustées dans les ensembles d'entraînement des plis et non sur l'ensemble complet.

Présentation des modèles

Modèle de référence : persistance

La persistance suppose que l'inflation annuelle dans douze mois sera égale à l'inflation connue aujourd'hui : prévision(t+12) = INFLATION_YOY(t). Aucun coefficient n'est estimé. Ce modèle simple permet de vérifier si la complexité supplémentaire de Ridge ou Gradient Boosting produit réellement un gain.

Régression Ridge

Ridge est une régression linéaire régularisée. Elle combine les valeurs courantes et retardées des trois indicateurs, tout en pénalisant les coefficients trop élevés. Le notebook utilise une imputation par la médiane, une standardisation et un paramètre alpha égal à 1. La régularisation est utile lorsque les variables explicatives sont corrélées.

Gradient Boosting

Gradient Boosting construit successivement des arbres de décision. Chaque nouvel arbre cherche à corriger les erreurs des précédents. Le modèle utilisé comporte 100 arbres, un taux d'apprentissage de 0,05, une profondeur maximale de 2 et une graine aléatoire égale à 42. Il peut représenter des relations non linéaires, mais sa complexité ne garantit pas de meilleures performances.

Le RMSE est le critère principal : plus il est faible, plus les erreurs de prévision sont réduites. Le MAE mesure l'erreur absolue moyenne. Le coefficient R^2 compare le modèle à une prédiction constante égale à la moyenne de la cible du jeu évalué.

Résultats et comparaison des modèles

Validation croisée temporelle

Modèle	RMSE moyen	Écart-type RMSE
Persistance	1.996	0.754
Ridge	2.916	1.253
Gradient Boosting	3.363	1.254

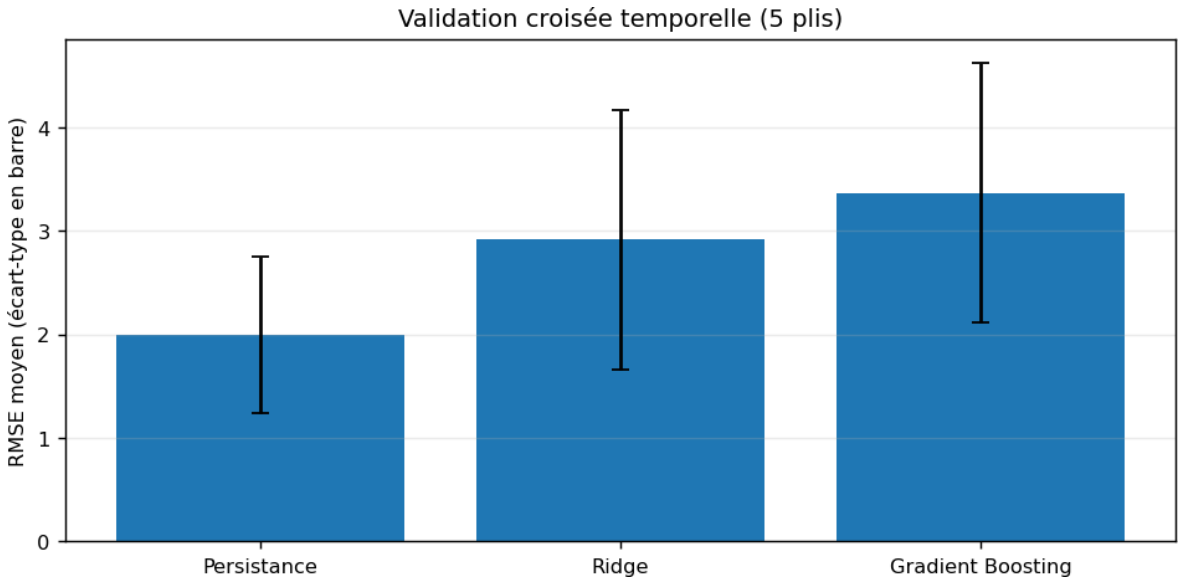


Figure 5 — RMSE moyen en validation croisée ; les barres indiquent l'écart-type entre les plis.

La persistance obtient le RMSE moyen le plus faible (1.996). Ridge atteint 2.916, soit environ 46.1 % de plus. Gradient Boosting atteint 3.363, soit environ 68.5 % de plus. La validation croisée désigne donc déjà la persistance comme meilleure méthode.

Les écarts-types des scores montrent que les erreurs changent d'un pli à l'autre. Cette variabilité est cohérente avec une série longue qui traverse plusieurs régimes économiques. Le classement doit néanmoins être confirmé sur le jeu de test final.

Évaluation finale sur le jeu de test

Modèle	RMSE	MAE	R^2
Persistance	2.084	1.470	-0.095
Gradient Boosting	2.557	1.771	-0.649
Ridge	2.836	2.004	-1.029

La référence de persistance conserve le meilleur résultat sur le test : RMSE = 2.084 et MAE = 1.470. Le RMSE de Gradient Boosting est supérieur de 22.7 % à celui de la persistance, et celui de Ridge est supérieur de 36.1 %. Les deux modèles de machine learning dégradent donc la précision globale au lieu de l'améliorer.

Les trois R^2 sont négatifs. Cela signifie que les modèles font moins bien, sur ce test, qu'une prédiction constante égale à la moyenne des valeurs cibles du test. Ce résultat montre que la tâche est difficile et que même la meilleure des trois approches reste imparfaite.

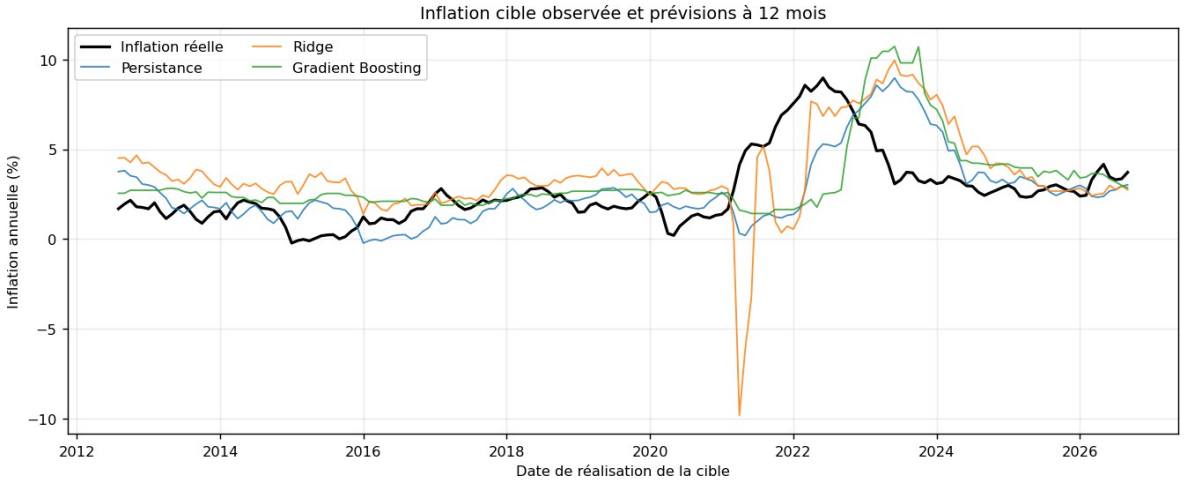


Figure 6 — Inflation réelle et prévisions des trois modèles sur le jeu de test.

La figure permet de comparer la trajectoire réelle aux prévisions. La persistance prolonge le niveau d'inflation observé à la date de départ. Elle bénéficie de l'inertie de la série, mais ne peut anticiper exactement les accélérations ou les ralentissements qui se produisent au cours des douze mois suivants. Les modèles Ridge et Gradient Boosting utilisent davantage de variables, mais leurs erreurs globales sont plus importantes.

Analyse des erreurs et apprentissage

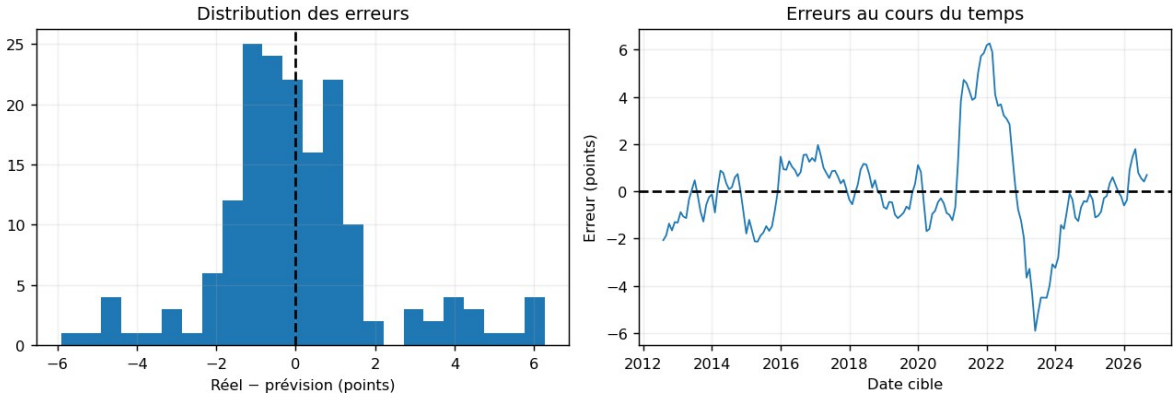


Figure 7 — Distribution et évolution des erreurs de la persistance.

Pour la persistance, l'erreur moyenne (inflation réelle moins prévision) est de 0.028 point, proche de zéro. 43.8 % des erreurs sont positives, donc correspondent à une sous-estimation ; 56.2 % sont négatives, donc correspondent à une surestimation. 52.7 % des prévisions ont une erreur absolue inférieure ou égale à un point, et 80.5 % une erreur inférieure ou égale à deux points.

Ces statistiques montrent que la persistance ne présente pas de biais moyen important sur toute la période test, mais qu'elle commet des erreurs substantielles à certaines dates. La proximité de l'erreur moyenne avec zéro ne signifie pas que les prévisions individuelles sont exactes : les sous-estimations et surestimations peuvent se compenser.

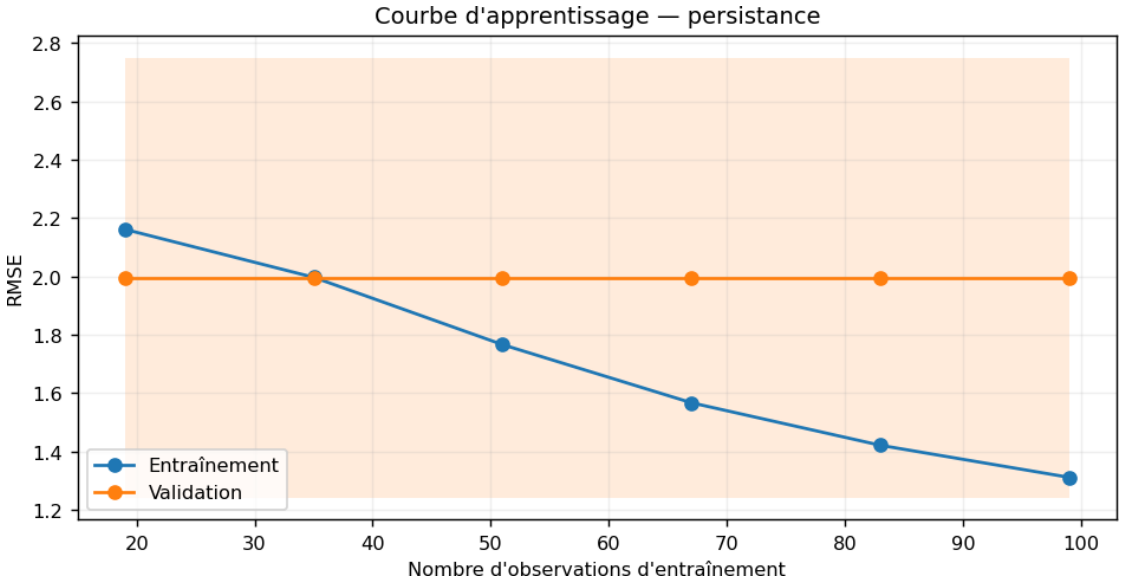


Figure 8 — Courbe d'apprentissage de la référence de persistance.

La courbe d'apprentissage est un diagnostic complémentaire. La persistance ne possède pas de paramètres appris : elle reprend directement la variable INFLATION_YOY. Il faut donc interpréter cette courbe avec prudence, car elle n'a pas la même signification que pour une régression qui estime des coefficients.

Interprétation des variables

Le modèle retenu après validation croisée est la persistance. Il ne consulte que l'inflation annuelle courante pour produire sa prévision. Les variables UNRATE, FEDFUNDS et les retards n'interviennent donc pas dans sa sortie.

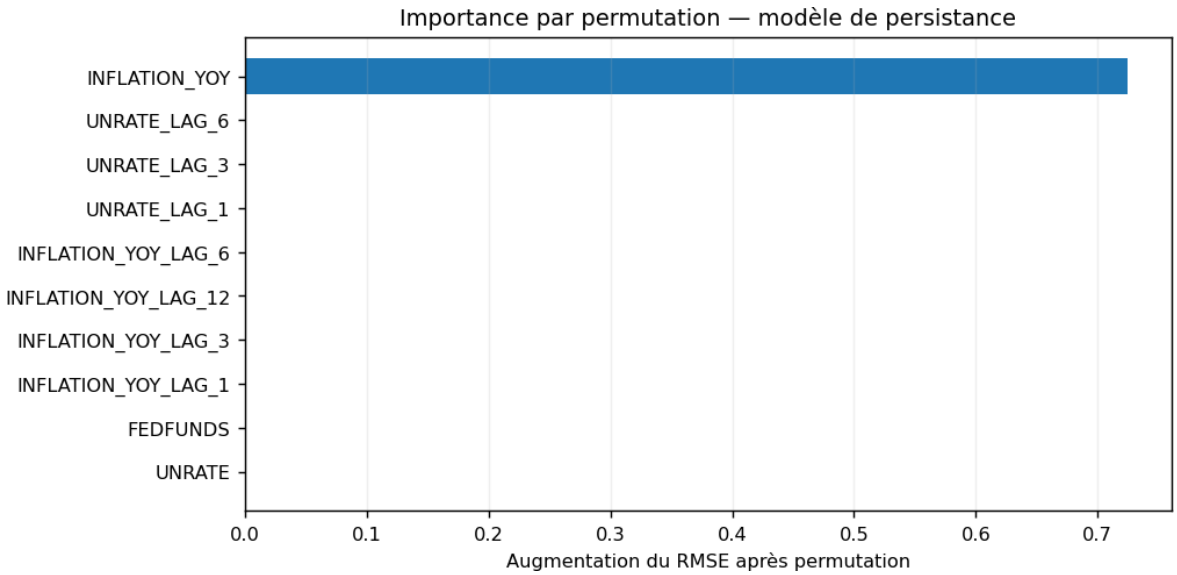


Figure 9 — Importance par permutation appliquée au modèle de persistance.

L'importance par permutation confirme ce fonctionnement : mélanger INFLATION_YOY augmente le RMSE d'environ 0.725 point en moyenne, alors que permuter les autres variables ne modifie pas les prédictions de la règle de persistance. Ce résultat est mécanique et ne signifie pas que le chômage ou le taux directeur n'ont aucune information économique. Il indique que le modèle sélectionné n'en a pas besoin.

Ainsi, l'analyse des variables ne permet pas d'affirmer que le chômage et le taux directeur expliquent l'inflation dans le modèle final : le modèle final ne les utilise pas. C'est un résultat essentiel pour répondre sans exagération à la problématique.

Prévision finale à douze mois

La dernière date où les trois indicateurs et l'inflation annuelle sont simultanément disponibles est septembre 2026. L'inflation annuelle observée à cette date est de 3.717 %. Comme le modèle sélectionné est la persistance, la prévision à douze mois reprend cette valeur.

Élément	Résultat
Modèle retenu	Persistance
Date de départ	September 2026
Date cible	September 2027
Inflation annuelle prévue	3.72 %

Cette valeur de 3,72 % constitue une référence de prévision et non une projection économique complète. Elle repose sur l'hypothèse que l'inflation annuelle reste au niveau de la dernière observation

disponible. Un choc sur les prix, une modification de la politique monétaire ou un changement de la demande pourrait conduire à un résultat différent.

Limites et pistes d'amélioration

Malgré les différentes étapes de préparation et de modélisation réalisées, plusieurs limites doivent être prises en considération pour interpréter correctement les résultats obtenus.

Premièrement, les données macroéconomiques historiques peuvent être révisées après leur première publication. Les valeurs actuellement disponibles dans FRED ne correspondent donc pas nécessairement aux chiffres qui étaient connus des analystes à la date où une prévision aurait été produite. L'utilisation des séries révisées peut introduire un biais d'anticipation (look-ahead bias) et conduire à une évaluation différente de celle qui aurait été obtenue en temps réel. Le notebook ne reconstitue pas les différentes versions historiques des données.

Deuxièmement, les dates de publication des indicateurs ne sont pas intégrées dans le dispositif de prévision. Le modèle utilise les valeurs mensuelles disponibles dans les séries comme si elles étaient connues immédiatement à la fin du mois concerné. En pratique, le CPI, le taux de chômage et le taux directeur ne sont pas nécessairement publiés au même moment. Cette simplification doit être prise en compte lorsqu'on interprète la prévision comme un exercice proche d'une situation réelle.

Troisièmement, les paramètres des modèles Ridge et Gradient Boosting ont été fixés dans le notebook et n'ont pas fait l'objet d'une optimisation approfondie. Il est donc possible que d'autres choix de paramètres, de transformations ou de variables explicatives produisent des résultats différents. Toutefois, toute optimisation devrait être réalisée uniquement à partir des données d'entraînement et au moyen d'une validation chronologique, afin de ne pas utiliser indirectement le jeu de test pour sélectionner le meilleur modèle.

Quatrièmement, les relations entre les variables macroéconomiques peuvent évoluer au cours du temps. Les crises économiques, les chocs énergétiques, les changements de politique monétaire et les transformations du marché du travail peuvent modifier la dynamique de l'inflation. Un modèle estimé sur une longue période peut ainsi combiner des contextes économiques très différents. Les trois variables retenues ne couvrent par ailleurs qu'une partie des facteurs susceptibles d'influencer les prix.

Enfin, les performances observées doivent être interprétées dans le périmètre précis de cette étude. Le modèle de persistance obtient les meilleurs résultats parmi les trois approches comparées, mais son R^2 sur le jeu de test reste négatif (-0,095) et son MAE demeure de 1,470 point de pourcentage. Il ne s'agit donc pas d'une prévision parfaitement précise. De même, le fait que Ridge et Gradient Boosting ne dépassent pas la référence ne permet pas de conclure que le chômage et le taux directeur sont dépourvus d'importance économique : cela signifie uniquement que leur intégration, selon les variables, les retards et les paramètres testés, n'a pas amélioré les performances prédictives.

Ces limites montrent que les résultats doivent être considérés comme une évaluation expérimentale des méthodes retenues et non comme une représentation exhaustive de tous les mécanismes qui déterminent l'inflation. Elles permettent également d'identifier plusieurs possibilités d'amélioration pour de futurs travaux.

Conclusion

Ce projet avait pour objectif d'étudier la capacité de certains indicateurs macroéconomiques à contribuer à la prévision de l'inflation américaine à un horizon de douze mois. Plus précisément, il s'agissait de déterminer si le taux de chômage et le taux directeur, combinés à l'inflation passée, permettent d'obtenir de meilleures prévisions qu'une méthode simple fondée sur la dernière valeur connue de l'inflation. Cette problématique s'inscrit dans une démarche de science des données appliquée à la finance, où l'enjeu consiste à transformer des séries économiques historiques en informations utiles pour anticiper une évolution future.

Pour répondre à cette question, nous avons travaillé à partir de trois séries mensuelles issues de FRED : l'indice des prix à la consommation CPIAUCSL, le taux de chômage UNRATE et le taux effectif des fonds fédéraux FEDFUNDS. Après l'alignement des séries sur un calendrier mensuel et le traitement des observations manquantes, l'inflation annuelle a été calculée à partir de la variation du CPI sur douze mois. La préparation des données a ensuite consisté à construire une cible correspondant à l'inflation annuelle observée douze mois plus tard, à créer des retards de 1, 3, 6 et 12 mois pour les variables étudiées et à séparer chronologiquement les observations d'entraînement et de test.

Trois approches ont été comparées : le modèle de persistance, utilisé comme référence, la régression Ridge et le modèle Gradient Boosting. La validation croisée temporelle et l'évaluation finale sur le jeu de test ont permis de comparer leurs erreurs de prévision. Les résultats montrent que le modèle de persistance est le plus performant dans les deux exercices. Il obtient un RMSE moyen de 1,996 en validation croisée et un RMSE de 2,084 sur le jeu de test, contre respectivement 2,916 et 2,836 pour Ridge, et 3,363 et 2,557 pour Gradient Boosting.

Le modèle de persistance présente également le MAE le plus faible sur le jeu de test, avec une valeur de 1,470 point de pourcentage. Cependant, les trois modèles présentent un R^2 négatif sur cet ensemble. Ce résultat invite à nuancer la conclusion : même si la persistance constitue la meilleure approche parmi celles qui ont été testées, ses performances restent limitées et ne doivent pas être interprétées comme une capacité de prévision élevée ou certaine. La prévision illustrative de 3,72

La réponse à la problématique est donc la suivante : dans le cadre de cette expérimentation, l'ajout du taux de chômage et du taux directeur, avec leurs valeurs retardées, n'a pas permis d'améliorer la prévision de l'inflation à douze mois par rapport à une prévision fondée sur l'inflation actuelle. Ce résultat ne signifie pas que ces indicateurs n'ont aucun rôle dans les mécanismes économiques. Il montre plutôt que, compte tenu des données, des variables, des retards et des paramètres utilisés, les modèles Ridge et Gradient Boosting n'ont pas réussi à exploiter ces informations pour obtenir une erreur de prévision plus faible que celle de la référence.

Cette étude met ainsi en évidence l'importance de comparer les modèles de Machine Learning à une méthode de référence simple et de respecter la dimension temporelle des données. Elle rappelle qu'un modèle plus complexe n'est pas nécessairement plus performant et que la qualité d'une démarche prédictive doit être jugée à partir de résultats obtenus sur des observations qui n'ont pas servi à l'apprentissage. Les limites liées aux révisions des données, aux dates de publication, aux changements de régime économique et au choix des variables doivent également être prises en compte avant toute utilisation pratique des prévisions.

Au-delà des résultats numériques, ce travail a permis de mettre en œuvre les principales étapes d'un projet de science des données appliqué à une problématique financière : collecte et compréhension des données, nettoyage, alignement temporel, création de variables, entraînement de modèles, validation chronologique, comparaison des métriques et interprétation économique. Il constitue une première démarche d'analyse prédictive et fournit plusieurs pistes d'amélioration, notamment l'ajout de variables macroéconomiques complémentaires, l'optimisation rigoureuse des paramètres et l'intégration des dates réelles de publication des indicateurs.

En définitive, ce projet nous a permis de comprendre que la prévision économique ne dépend pas uniquement du choix d'un algorithme performant, mais également de la qualité des données, de la pertinence des variables retenues et de la rigueur de la méthode d'évaluation. Il souligne ainsi l'importance d'une approche critique des résultats obtenus et de leur interprétation dans leur contexte économique.

Références et sources

Federal Reserve Bank of St. Louis, Federal Reserve Economic Data (FRED), https://fred.stlouisfed.org/.
CPIAUCSL : https://fred.stlouisfed.org/series/CPIAUCSL ;
UNRATE : https://fred.stlouisfed.org/series/UNRATE ;
FEDFUNDS : https://fred.stlouisfed.org/series/FEDFUNDS.

Scikit-learn, documentation officielle : https://scikit-learn.org/stable/ (TimeSeriesSplit, Ridge, GradientBoostingRegressor, permutation_importance).